

02

Kaggle Santander Bank Customer Satisfaction

□ 머신러닝 세미프로젝트 로드맵 구성

- 마감 및 프로젝트 일정이 촉박하여 조원별 업무 및 작업을 배분하여 프로젝트 진행
- 주제별로 차례대로 진행하였으며, 수업 시간의 모델 성능을 타겟으로 고도화 작업에 집중


< Semi-Project 추진 일정 (11월 18일 ~ 12월 15일) >

구 분	D4	D8	D12	D16	D20
○ 프로젝트 전략 및 계획 수립					
○ 조원별 업무 배분 및 업무 범위 명확화					
○ 주제별 데이터셋 파악, 전처리 과정 진행					
○ 주제 1 : Kaggle 산탄데르 은행 고객 만족 분석					
○ 주제 2 : Kaggle 신용카드 사기 검출					
○ 주제 3 : UCI 감성 리뷰 분석 및 문서 유사도 분석					
○ 주제 4 : Kaggle Mercari 가격 예측					
○ 모델 학습 및 성능 고도화					
○ 리포트 작성 및 발표자료 준비					

❑ 불만족 고객 조기 파악 및 맞춤형 서비스 제공

- 고객 만족을 전략적 핵심 지표로 설정
- (데이터 기반 접근) 머신러닝을 통해 어떤 특성이 불만족을 유발하는지 파악
- NPS 기반 고객 경험 혁신
 - 충성 고객 확대, 디지털 전환 가속화, 글로벌 다각화


[그림 2.1 산탄데르 은행 고객 만족 중심 경영 전략]



□ NPS(Net Promoter Score)

- 고객 추천 의향 지표
- (계산) 추천 고객 비율 - 비추천 고객 비율
- (금융업계 활용) **충성도** 및 **장기 수익성** 예측
 - 전략적 지표(NPS)와 데이터 기반 머신러닝 예측을 결합하여, 고객 충성도와 불만족 관리 집중

[그림 2.2 산탄데르 은행 NPS 성과 지표 (24' - 25')]





□ 2016년도 업계 현황 및 배경

- 08' 금융위기 이후 은행들은 신뢰회복과 건전성 강화에 집중
- 디지털 banking 확산, 고객 경험 경쟁 심화, 규제 강화 ▶ **충성 고객 확대, 디지털 전환 가속화**
 - “산탄데르가 고객 경험을 혁신하고 NPS 개선을 위해, 어떤 요인이 만족도에 영향을 주는지 데이터 분석을 통해 규명

[그림 2.3 산탄데르 은행 디지털 전환 및 고객중심 경영 만족도 NPS 조사 (2019)]

Best-in-class Global payments and digital banking solutions to SMEs and Individuals





자료 : NPS – Customer Satisfaction by Stiga / Deloitte

□ 데이터셋 및 불균형 문제

- 데이터셋 : 약 7만 6천여명 고객과 371개 변수 (0 : 만족, 1 : 불만족)
- 모든 변수명이 개인정보 보호를 위해 암호화 되어있음
- 불만족 고객은 소수(약 4%)로 데이터 불균형 존재
 - (피처명) ID : 고객 고유 식별 번호, var3 : 고객 나이 또는 계좌개설 후 경과 개월수, var15 : 고객 연령대
 - var3 중 -99999 는 명시적 결측치


[그림 2.4 산탄데르 데이터셋 TARGET(레이블) 분포 시각화]



□ 불균형 데이터셋에서의 ROC-AUC

- 극심한 불균형 데이터셋에서의 정확도(Accuracy)의 한계점 존재
- 모델의 분류 성능을 시각적으로 확인
 - X축 : (FPR) 실제 만족 고객인데 불만족으로 잘못 분류한 비율
 - Y축 : (TPR) 실제 불만족 고객을 올바르게 분류한 비율
 - AUC : ROC 곡선 아래 면적 → 1.0에 가까울수록 완벽한 분류, 0.5에 가까울수록 랜덤 추측
 - 모델 자체의 내재적 변별 능력 평가, 비교에 유용한 지표

[그림 2.5 산탄데르 ROC 곡선 시각화 (트리계열 알고리즘 사용)]



□ 데이터셋 describe()

- 각 피처들의 평균, 표준편차, 최소/최댓값 기본 통계치 출력
- 데이터 구조적 특성 및 모델링 전략 힌트 파악
- 피처명 의미가 없어 직접적 해석 불가 ► **EDA(탐색적 데이터 분석), Feature Selection 중요**
 - 피처 분포와 스케일
 - 결측치 및 이상치 탐지 및 클래스 불균형 확인
 - 피처 중요도 추정 및 Feature Engineering 방향성 확인



[그림 2.6 로드된 산탄데르 데이터셋 데이터프레임 describe()]

	ID	var3	var15	var38	TARGET
count	76020.000000	76020.000000	76020.000000	7.602000e+04	76020.000000
mean	75964.050723	-1523.199277	33.212865	1.172358e+05	0.039569
std	43781.947379	39033.462364	12.956486	1.826646e+05	0.194945
min	1.000000	-999999.000000	5.000000	5.163750e+03	0.000000
25%	38104.750000	2.000000	23.000000	6.787061e+04	0.000000
50%	76043.000000	2.000000	28.000000	1.064092e+05	0.000000
75%	113748.750000	2.000000	40.000000	1.187563e+05	0.000000
max	151838.000000	238.000000	105.000000	2.203474e+07	1.000000
8 rows × 371 columns					

주요 피처 분석

- 익명화된 피처 중 **고객불만족을 가장 잘 설명하는 피처를 찾아내는 과정**
- 해당 과정을 통해 모델 성능을 높이고, 고객 이탈을 예방
 - 불균형 클래스 문제를 통해 **Accuracy** 보다 **ROC-AUC** 지표가 더 적합
 - 피처중요도를 계산 및 상관관계를 계산하여 시각화 → 주요 피처들의 히스토그램 / Heatmap

[그림 2.7 'var38(자산 규모 추정)' 히스토그램, 로그 변환 전후 비교]



[그림 2.8 일부 20개 피처들의 상관관계 Heatmap 시각화]

□ 주요 피처 분석을 통한 시사점

- 익명화된 피처 중 일부는 불만족 고객을 강하게 구분하는 경향을 보였음
- 상관계수가 높은 컬럼들을 삭제하여 다중공선성 문제 해결 필요
- 로그변환을 이용하여 데이터의 비대칭적 분포(왜도) 완화하여 이상치 영향력 감소 필요
- SMOTE 또는 스케일링을 활용하여 학습 데이터 균형을 맞추되, 어떤 피처가 잘 작동하는지 확인 필요
- 산탄데르 은행의 실무적 인사이트 :
 - 주요 피처를 중심으로 불만족 고객 조기 탐지
 - 모델이 강조하는 피처들을 실제 서비스 개선지표로 활용
 - ‘단순히 모델이 불만족 고객이라고 예측했다’가 아니라, 어떤 요인 때문에 불만족 가능성이 높은지 설명이 되어야 함

1. 고객 이탈 예방
2. 서비스 개선 포인트
3. 설명 가능성 확보




- ✓ 맞춤형 대응 전략 수립
- ✓ 서비스 개선지표 활용
- ✓ 불만족 가능성 요인 설명

❑ 피처들의 성격파악 및 시각화 분석


- (데이터 특성 파악) 고유값 개수 확인을 통한 범주형 또는 연속형 컬럼 구분
- (데이터 이상치 탐지) 전체 컬럼 분포, 이상치 분포도 시각화 ▶ 데이터 전처리 및 피처선택 전략 수립
 - 피처 분포 시각화를 통한 고유값 확인 : 고유값이 너무 적거나 많은 컬럼 ▶ 제거 또는 변환 대상 (Feature Selection)
 - 대부분의 피처는 비대칭적 분포를 보였으며, 일부 피처에서 매우 큰 값, 대부분이 0에 집중된 경향 관찰

[그림 2.8 컬럼별 분포 시각화 및 고유값 확인]

컬럼 분포 시각화 (1~5)



[그림 2.9 이상치가 100개 이상인 컬럼 상위 5개 boxplot 시각화]



□ 왜도 특성 파악 및 피처간 상관관계 분석

- 왜도 분석을 통해 데이터 분포의 비대칭성 지표 파악 후, **로그 변환** 적합 여부 판단
- (피처간 상관관계 분석) 특정 피처들에서 강한 상관관계 확인 ► **다중공선성 존재**
- (다중공선성 영향) 계수 불안정성, 모델 해석력 저하, 과적합 가능성 ► **중복 정보 탐지**
 - 전체 데이터 중 음수 값을 가지는 컬럼은 총 31개로 확인 → 로그변환은 양수에만 적용 (다른 비선형 기법 고려)
 - 분할 기준에 따라 변수 중요도를 선택적으로 반영하는 트리 계열 알고리즘과 달리, **선형계열 모델에는 민감한 영향**

[그림 2.10 데이터셋 왜도 분석 및 로그변환 판단 함수 적용]

=====

왜도(Skewness) 분석

=====

전체 컬럼 수: 369

왜도 > 3.0: 315개

왜도 > 5: 293개

왜도 > 10: 242개

상위 20개 컬럼:

순위	컬럼명	왜도	최소값	최대값	Log변환
1	num_reemb_var33_ult1	275.72	0.00	3.00	가능
2	num_reemb_var17_hace3	275.72	0.00	3.00	가능
3	imp_trasp_var33_out_ult1	275.72	0.00	3000.00	가능
4	num_trasp_var33_out_ult1	275.72	0.00	3.00	가능
5	imp_reemb_var33_ult1	275.72	0.00	1200.00	가능
6	delta_num_trasp_var33_out_1y3	275.72	0.00	999999999.00	가능
7	delta_imp_trasp_var33_out_1y3	275.72	0.00	999999999.00	가능
8	saldo_medio_var29_hace3	275.72	0.00	145.20	가능
9	delta_num_aport_var33_1y3	275.72	-1.00	999999999.00	불가(음수)
10	delta_imp_reemb_var33_1y3	275.72	0.00	999999999.00	가능

[그림 2.11 상위 20 피처들의 상관관계 히트맵 시각화]

Correlation Matrix (Top 20 Variables)


Variable	var3	var15	imp_ent_var16_ult1	imp_op_var33_comer_ult1	imp_op_var33_comer_ult3	imp_op_var41_comer_ult1	imp_op_var41_comer_ult3	imp_op_var41_efect_ult1	imp_op_var41_efect_ult3	imp_op_var1_ult1	imp_op_var39_comer_ult1	imp_op_var39_efect_ult1	imp_op_var39_efect_ult3	ind_var1_0	ind_var5_0	ind_var6_0	ind_var8_0	ind_var12_0	ind_var12	
var3	1.00	0.12	0.00	0.10	0.17	0.08	0.13	0.04	0.06	0.03	0.04	0.06	0.04	0.11	-0.21	-0.06	0.01	0.01	0.00	
var15	0.12	1.00	0.04	0.09	0.10	0.09	0.09	0.07	0.10	0.09	0.07	0.11	0.11	-0.11	-0.10	0.11	0.10	0.26	0.22	
imp_ent_var16_ult1	0.00	0.04	1.00	0.04	0.03	0.04	0.03	0.02	0.02	0.04	0.02	0.02	0.04	0.02	-0.00	0.02	0.00	0.01	0.04	
imp_op_var33_comer_ult1	0.10	0.09	0.04	1.00	0.89	0.96	0.86	0.29	0.26	0.65	0.29	0.26	0.67	0.23	-0.22	0.04	0.22	0.24	0.01	
imp_op_var33_comer_ult3	0.17	0.10	0.03	0.89	1.00	0.85	0.96	0.27	0.28	0.57	0.27	0.28	0.59	0.23	-0.23	0.03	0.20	0.22	0.01	
imp_op_var41_comer_ult1	0.08	0.09	0.04	0.96	0.85	1.00	0.89	0.28	0.26	0.66	0.28	0.26	0.65	0.15	-0.20	0.04	0.22	0.24	0.01	
imp_op_var41_comer_ult3	0.13	0.09	0.03	0.86	0.96	0.89	1.00	0.27	0.28	0.58	0.26	0.28	0.58	0.17	-0.21	0.04	0.20	0.22	0.01	
imp_op_var41_efect_ult1	0.04	0.09	0.02	0.29	0.27	0.28	0.27	1.00	0.81	0.89	1.00	0.81	0.88	0.10	-0.16	0.01	0.18	0.19	0.01	
imp_op_var41_efect_ult3	0.06	0.07	0.02	0.26	0.28	0.26	0.28	0.81	1.00	0.72	0.81	1.00	0.72	0.12	-0.14	0.01	0.15	0.17	0.01	
imp_op_var1_ult1	0.03	0.10	0.04	0.65	0.57	0.66	0.58	0.89	0.72	1.00	0.88	0.72	0.89	0.14	-0.21	0.03	0.24	0.26	0.01	
imp_op_var39_comer_ult1	0.04	0.09	0.02	0.29	0.27	0.28	0.26	1.00	0.81	0.88	1.00	0.81	0.88	0.11	-0.16	0.01	0.18	0.19	0.01	
imp_op_var39_efect_ult1	0.06	0.07	0.02	0.26	0.28	0.26	0.28	0.81	1.00	0.72	0.81	1.00	0.72	0.12	-0.14	0.01	0.15	0.17	0.01	
imp_op_var39_efect_ult3	0.04	0.11	0.04	0.67	0.59	0.65	0.58	0.88	0.72	0.99	0.88	0.72	1.00	0.18	-0.21	0.03	0.24	0.26	0.01	
ind_var1_0	0.11	0.11	0.02	0.23	0.23	0.15	0.17	0.10	0.12	0.14	0.11	0.12	0.18	1.00	-0.19	-0.04	0.12	0.13	0.11	
ind_var5_0	-0.21	-0.11	-0.00	-0.22	-0.23	-0.20	-0.21	-0.16	-0.14	-0.21	-0.16	-0.14	-0.21	-0.19	1.00	0.29	-0.67	-0.81	-0.08	
ind_var6_0	-0.06	-0.10	0.02	0.04	0.03	0.04	0.04	0.01	0.01	0.03	0.01	0.01	0.03	0.04	0.29	1.00	-0.25	-0.24	-0.09	
ind_var8_0	0.01	0.11	0.00	0.22	0.20	0.22	0.20	0.18	0.15	0.24	0.18	0.15	0.24	0.12	-0.07	-0.25	1.00	0.93	0.02	
ind_var12_0	0.01	0.10	0.01	0.24	0.22	0.24	0.22	0.19	0.17	0.26	0.19	0.17	0.26	0.13	-0.81	-0.24	0.93	1.00	0.02	
ind_var12	0.00	0.26	0.04	0.01	0.01	0.01	0.01	0.01	0.01	0.01	0.01	0.01	0.01	0.11	-0.08	-0.09	0.02	0.02	1.00	
ind_var12	0.01	0.22	0.05	0.02	0.02	0.02	0.02	0.01	0.01	0.01	0.01	0.01	0.01	0.02	-0.09	-0.09	0.03	0.04	0.81	1.00

02-5 탐색적 데이터 분석(EDA)


❑ var3 , var15, var38 발견된 문제점

- var3 피쳐 describe() 를 통해 **최소값 -999999 결측치** 확인
- var15 값의 분포가 현실적인 '**나이(Age)**' 범위에 해당, 연속형 정수로 구성 ▶ **고객 특성 설명**
- var38 피쳐의 분포 분석 결과 **특정 값***에 데이터가 집중되는 패턴 확인 ▶ **결측치 대체값(placeholder) 시사**
 - var15 나이 추정 변수에서 전체 분포는 23~40세 구간에 집중, **100세 이상 값은 총 8건**으로 매우 드물게 나타나 이상치로 판단
 - var38 특정 값(117,310)에 데이터가 집중되는 패턴 확인. 해당값은 전체 데이터 14,868건으로 가장 높은 빈도를 보임

[그림 2.12 var15(나이추정) 피쳐의 분포 히스토그램]



[그림 2.13 var38 피쳐의 분포 중 특정값 데이터 집중 확인]



□ 모델 성능과 안정성 확보를 위한 단계적 전처리 진행

- 탐색적 데이터 분석을 통한 데이터 전처리와 피처 선택 전략 수립
- (결측치 처리) 명시적 결측치를 최빈값으로 대체하여 데이터 일관성 확보
- (zero 값 의미 파악 및 처리) 0 값이 지나치게 높은 비율로 나타나는 피처 제거 ⇒ 피처 220개 제거
 - var3 피처 -999999, 최빈값 2로 대체
 - zero_count_rate 통해 전체 값 중 99% 이상이 0으로 구성된 피처들은 정보량이 거의 없다고 판단하여 삭제

[표 2.1 전처리 전체 단계 요약 구성]

단계	주요 내용
1. 데이터 정제	▪ 비표준 값 처리 및 결측치 치환 전략 적용
2. 피처 선택 (1)	▪ Zero-value 비율 분석에 따른 피처 제거
3. 이상치 처리	▪ 이상치 탐지 및 값 보정
4. 변수 변환	▪ 고 왜도 변수에 대한 로그 변환 적용
5. 피처 선택 (2)	▪ 다중공선성 해소를 위한 상관관계수 기반 피처 제거
6. 인코딩/스케일링	▪ 필요 시 인코딩 적용 및 스케일 정규화
7. 최종 확정	▪ 최종 Feature 목록 확정

[표 2.2 var3 결측치 처리 및 0값이 99%이상인 피처 제거 함수]

```
# var3처리

X_features['var3'] = X_features['var3'].replace(-999999, 2)
X_test['var3'] = X_test['var3'].replace(-999999, 2)

def remove_zero_columns2(train_df, test_df, threshold_rate=0.99, save_report=True):
    summary_data = [ ]
    for col in train_df.columns:
        zero_count = (train_df[col] == 0).sum()
        ...
    return clean_train_df, clean_test_df
```

□ 모델 성능과 안정성 확보를 위한 단계적 전처리 진행

- 다중공선성 문제 해결을 위한 피처간 상관관계 계산 ⇒ **상관계수 절대값이 0.95 이상인 피처 제거**
- 연속형 변수 var15(나이 추정) 비정상적 큰 값, 극단값 포함 ⇒ **상한값 100으로 제한**
- 왜도 절대값이 높은 피처들에 대한 log1p 변환 적용 ⇒ **총 71개 피처 변환 대상 선정**
 - 모델 학습 시 불필요한 복잡도 증가 및 과적합(over fitting) 유발 방지를 위해 **상관계수가 높은 피처들 53개 제거** ⇒ 96개로 축소
 - 중요도가 높고, 나이로 추정되는 var15 피처 중 100이 넘는 값들이 분포 왜곡을 발생시킬 가능성이 있음 ⇒ 현실적 범위 내 학습 유도
 - 왜도(skewness) 절대값이 높은 변수는 모델의 결정 경계 형성을 왜곡 ⇒ 로그변환을 통한 해당 피처 분포 안정적 개선

[표 2.3 상관계수 높은 피처 삭제 함수]

```
def drop_highly_correlated_features(df, threshold=0.95):  
    corr_matrix = df.corr().abs()  
    upper = corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(bool))  
    to_drop = [column for column in upper.columns if any(upper[column] > threshold)]  
    return df.drop(columns=to_drop), to_drop
```

[표 2.4 var15 피처(나이 추정) 이상치 제한 함수]

```
X_features['var15'] = X_features['var15'].clip(upper=100)
```

[표 2.5 음수를 제외한 고 왜도 피처 log1p 적용 및 확인 함수]

```
# Train에 log 변환 적용  
X_reduced[valid_log_cols] = np.log1p(X_reduced[valid_log_cols])  
  
# Test에도 동일하게 적용  
X_test_reduced[valid_log_cols] = np.log1p(X_test_reduced[valid_log_cols])  
print(f"✓ Log1p 변환 완료: {len(valid_log_cols)}개 컬럼")  
  
# 변환 후 왜도 확인  
new_skewness = X_reduced[valid_log_cols].skew()  
print(f"✓ 변환 후 평균 왜도: {abs(skewness[valid_log_cols]).mean():.2f} -> {abs(new_skewness).mean():.2f}")  
else:  
    print("✓ Log 변환 적용 가능한 컬럼이 없습니다.")
```

□ 모든 피처 스케일링을 통한 정규화 작업 실시

- 모델 간 공정한 비교를 위한 **모든 피처에 StandardScaler** 적용
- 추가적인 인코딩 작업은 수행하지 않았음(One-Hot Encoding, Label Encoding X)
 - 스케일링을 통해 트리계열 모델들은 변수 스케일에 민감하지 않지만, 입력값 크기 차이에 영향을 받는 회귀 모델과 공정한 비교 가능

□ 단계적 전처리를 통한 최종 Feature Selection 요약

- 원본 데이터(371개 피처) 중 불필요하거나, 품질저하 유발 요소 제거
- **최종적 96개 핵심 피처 선정**
 - 모델 학습 효율성 향상
 - 과적합 방지와 해석 가능성 제고 기여

[표 2.6 학습, 테스트데이터 StandardScaler 정규화 함수]

```
def scale_data(X_train, X_test :  
    scaler = StandardScaler()  
    X_train_scaled = scaler.fit_transform(X_train)  
    X_test_scaled = scaler.transform(X_test)  
  
    return X_train_scaled, X_test_scaled, scaler
```


□ 8:2 학습/검증 데이터 분할

- 80% 학습용 Train 데이터로 사용, 나머지 20%는 검증용 Validation 으로 사용
- Cross-Validation 전략 사용
 - 20% 검증용 데이터들은 검증용으로 사용 → 모델 선택 및 하이퍼파라미터 튜닝 활용
 - **Stratified Kfold 기반 교차검증** 사용 → 각 fold 마다 TARGET 클래스 비율, 전체 데이터와 유사하게 유지되도록 층화 설정
 - HyperOpt 및 GridSearchCV 에서 단일 Train/Validation 분할에 의존하지 않는 안정적 성능 평가 수행

[표 2.7 StratifiedKfold 기반 교차검증 사용 적용 함수]

```
stacking_model = StackingClassifier(  
    estimators    = [('rf', rf_clf), ('xgb', xgb_clf), ('lgbm', lgbm_clf)],  
    final_estimator = meta_model,  
    cv            = StratifiedKFold(n_splits=5, shuffle=True, random_state=42),  
    n_jobs        = -1  
)
```

□ 베이스 라인 모델 선정 및 주요 평가지표 재선정

- Scikit-learn DummyClassifier 모델 사용
- 아무것도 학습하지 않은 모델 성능 기준 제시 $\Rightarrow$ 각 모델들로 얼마나 개선되었는지 비교
- Accuracy 의 한계 확인 ► **주요 평가지표 재선정**
 - ROC-AUC를 주요평가 지표로 선정
 - 소수 클래스(불만족)를 잘 찾아내는지 확인 $\Rightarrow$ Recall, F1-Score 를 보조 지표로 함께 사용

[그림 2.14 DummyClassifier 모델 성능 결과 Accuracy 한계점 확인]

```
DummyClassifier ROC-AUC: 0.5  
DummyClassifier Accuracy: 0.9604051565377533  
DummyClassifier Precision: 0.0  
DummyClassifier Recall: 0.0  
DummyClassifier F1 score: 0.0  
DummyClassifier Confusion Matrix:  
[[14602    0]  
 [  602    0]]
```

- ✓ ROC-AUC 약 0.5 수준(랜덤예측 수준)으로 실질적 분류 능력 없음
- ✓ 소수 클래스인 1에 대해 Recall, F1-Score는 거의 0에 가깝게 측정
- ✓ 불만족 고객을 사실상 찾아내지 못하는 모델 확인
- ✓ Accuracy 지표의 모델 품질 판단 한계점 존재

❑ XGBoost, LightGBM, RandomForest, LogisticRegression

- (Base 모델) XGBoost
- (Tree 계열) LightGBM, RandomForest
- (선형 모델) Logistic Regression
 - XGB ⇨ 불균형 데이터에서의 높은 성능, 정규화, 조기 종료 기능 고려
 - LGBM, RF ⇨ 학습 속도가 빠르고, 대용량 데이터에 적합
 - LR ⇨ 해석력 상승, 간단한 구현 (주요 변수 비교)

[표 2.8 선정된 모델별 ROC-AUC 성능 비교]

모델	ROC-AUC (Validation)	학습 시간
DummyClassifier	0.5	빠름
XGBoost (default)	0.8509	중간
XGBoost (tuned)	0.8402	느림
LightGBM (default)	0.8438	빠름
LightGBM (tuned)	0.8452	중간
Logistic Regression	0.8051	빠름
RandomForest	0.8422	느림


□ 각 모델별 주요 평가지표 및 추가 전처리 필요성 확인

- var3 피쳐 이상치(-999999) 최빈값 2로 대체
- StandardScaler 적용
- 모든 모델에서 Recall 및 F1-Score 값이 극도로 떨어지는 것을 확인 → 심각한 클래스 불균형
 - 추가적인 데이터 전처리 필요
 - 상관관계 비율 0.95 이상인 피쳐 삭제 (적용 예정)
 - 행 전체가 0값(99% 이상)인 피쳐 삭제 (적용 예정)

[표 2.9 첫번째 전처리 적용 후 모델별 주요 성과지표 성능 결과]

모델	데이터 전처리 적용 여부	ROC-AUC	F1-Score	Recall
XGBoost	var3 이상치 최빈값 대체 / StandardScaler	0.8509	0.2974	0.515
LightGBM	위와 동일	0.8438	0.0099	0.005
Logistic Regression	위와 동일	0.8051	0.0129	0.0066
RandomForest	위와 동일	0.8422	0.0163	0.0083

[그림 2.15 Threshold 임계값 수치별 삭제된 컬럼 비교 시각화]



□ 전처리 적용 후 주요 평가지표별 성능 변화 평가

- 추가적인 전처리 적용 후 모델별 성능 개선 확인
- 상관관계 비율이 0.95 이상인 피처 삭제
- 행 전체(99% 이상)가 0인 피처 삭제
- XGBoost의 성능 비정상적 수치 하락 발생 (원인 분석 진행) ▶ 불만족 예측률이 가장 높은 LogisticRegression 모델 채택 고려
 - Threshold 예측 임계값 조정 후 재학습
 - Class weight 미적용으로 불균형 처리 없이 학습 가능성
 - 전처리 과정에서 중요 정보 손실 가능성

[표 2.10 추가 전처리후 각 모델별 Recall 및 f1-score 성능 개선 확인]

모델	데이터 전처리 적용 여부	ROC-AUC	F1-Score	Recall
XGBoost	var3 이상치 최빈값 대체 / StandardScaler / 행전체 0인 피처 삭제 / 상관계수 0.95 이상 삭제	0.8520	0.0066	0.0033
LightGBM	위와 동일	0.8452	0.2870	0.5598
Logistic Regression	위와 동일	0.8063	0.1617	0.7724
RandomForest	위와 동일	0.8263	0.2653	0.3953


Feature Importance

- 모델별 주요 특성 파악을 통해 **var15, saldo_var30** 핵심 피처 확인
- 거래 금액 중심 특성을 보여주는 **LogisticRegression** 선형 모델의 단순함이 장점으로 적용
 - 트리 모델과 달리 선형 관계가 명확한 피처 선호

[표 2.11 모델 별 피처 중요도]

순위	XGBoost	LightGBM	RandomForest	LogisticRegression
1	Saldovar30	Var38	Var15	Imp_var7_recib_ult1
2	var15	var15	saldo_var30	saldo_var14
3	ind_var30_0	saldo_var30	var38	Saldo_medio_var5_hace3

[그림 2.16 모델별 피처 중요도 상위 10개 시각화]



□ 예측 vs 실제 비교

- 예측한 값과 실제 값을 비교를 위해 오차행렬 분석
- 실제 불만족 고객(1)과 만족 고객(0) 에 대한 예측 결과 비교
 - 예측 결과 : **LightGBM** 이 가장 좋은 밸런스를 가진 모델
 - 하지만, 모델을 바로 적용해야하는 상황에서는 **불만족 예측률이 가장 높은 LogisticRegression** 채택 고려

□ 오차 분석을 통한 문제점 파악

- 극심한 클래스 불균형 : 모델의 초기 성능(1차 평가)에서 Recall, F1-Score 수치 저하
- XGBoost의 예측 임계값/과소적합 문제 : 2차평가에서 TP 2건으로 분류기 역할 상실
 - 불균형 데이터에서 Recall 을 극대화하기 위해 예측 임계 값이 매우 낮게 설정 가능성
 - 고객 이탈 방지 기회는 최대화하지만, 대량의 마케팅 비용 비효율(FP) 유발

[표 2.12 모델별 오차행렬 및 주요 지표 비교]

모델	TN	FP	FN	TP	Precision	Recall	F1-Score
XGBoost	14,599	3	600	2	40%	0.33%	0.66%
LightGBM	13,193	1,409	265	337	19.31%	55.98%	28.70%
Logistic Regression	13,648	954	364	238	19.96%	39.53%	26.49%
RandomForest	9,913	4,689	137	465	9.03%	77.24%	16.08%

□ SHAP 분석

- 모델의 예측 결과를 각 피처가 얼마나 기여했는지 수치로 설명
- 전역적 중요 피처 재확인 및 영향력의 방향성
- 고객 불만족 유발 요인 집중 분석 (지역적 해석)
 - SHAP Force Plot 을 통해 불만족으로 예측된 고객들 특징 분석
 - SHAP 중요도에 따른 해당 피처의 **영향력 방향성** 및 **비즈니스 해석**
 - 숨겨진 패턴으로 LogisticRegression의 중요피처 (Imp_var7_recib_util1)는 트리 모델에서는 상대적으로 중요도가 낮았음
 - 선형 모델은 단순한 거래 금액과 같은 직접적 선형 관계에 집중했음을 시사

[표 2.13 SHAP 중요도에 따른 영향력 분석 및 비즈니스 해석 추정]

피처	SHAP 중요도(순위)	영향력의 방향성 (SHAP Value)	비즈니스 해석 (추정)
var15	최상위	▪ 값이 낮을수록 불만족 확률을 높임	▪ 고객 연령이 낮거나, 계정 보유 기간이 짧은 신규/젊은 고객일수록 불만족도가 높음
saldo_var30	상위권	▪ 값이 높거나 극히 낮을 경우 불만족 확률을 높임	▪ 계좌 잔액(var30관련)이 지나치게 많거나 극도로 적을 때 불만족과 관련됨
var38	상위권(특히 LGBM)	▪ 값이 특정 범위에 있을 때 불만족 확률을 높임	▪ 익명화된 주거 또는 자산 관련 정보로, 특정 경제적 배경을 가진 고객군에서 불만족이 집중
Ind_var30_0	중상위	▪ 피처가 0일 경우 불만족 확률을 높임	▪ var30관련 계좌가 존재하지 않을 때 (해당 상품을 이용하지 않을 때) 불만족과 연관됨

□ 스택킹 앙상블을 통한 리더보드 최상위권 도달

- RandomForest, XGBoost, LightGBM 을 베이스모델로, LogisticRegression 을 메타모델로 Stacking 앙상블 구성
- Stratified K-Fold 교차검증을 적용하여 불균형 데이터 문제 완화
- Threshold 변화에 따른 final Stacking 모델 불만족 고객 탐지 비율 분석
- 모델 기여도 계수 확인
 - ROC-AUC 는 최고 수준으로 모델 분류 능력을 잘 보여주었으나, F1-Score 는 낮게 나타나 Precision / Recall 간 균형 부족 확인
 - Recall 은 0.88로 매우 높아, 불만족 고객을 잘 탐지

[표 2.14 최종 스택킹 모델 Best 성능, 각 모델 기여도 및 주요지표 점수]

모델명	모델 기여도	주요 지표		
		ROC-AUC	F1-Score	Recall
RandomForest	1.85	0.9300	0.2934	0.8856
XGBoost	-0.67			
LightGBM	4.81			

□ 시사점 및 한계점 정리

- 불만족 고객을 조기에 파악해 대응할 수 있었지만, **오탐이 많으면 자원 낭비 및 고객 경험 악화 가능성**이 있다는 것을 재확인
- 학습결과에 따른 주요 피처분석을 통해 **var38(주거래 상품 잔액), var15(나이)**가 가장 중요한 피처로 확인
- **젊은 고객층에서 불만족 비율이 상대적으로 높은 것을 확인**
 - AUC 및 Recall 성능이 매우 우수하여 불만족 고객을 효과적으로 탐지 가능하지만, Precision 값이 낮아 오탐을 줄이는 추가적 후처리가 필요
 - 불필요한 마케팅/관리 비용 증가, 고객경험 저하, 자원낭비 발생 가능
 - Precision 이 낮으면 투입대비 성과가 떨어짐 → 불필요한 지출 발생

□ 제언

- (데이터 측면) 데이터 양 부족으로 일반화 성능에 제약 존재 및 재현율 편향 발생 가능성 ▶ **빅데이터 필요**
- (모델 측면) 트리계열 모델 해석의 한계점 존재, 피처수에 비해 샘플수가 적어 과적합 위험 ▶ **외부데이터 경제지표, 경쟁사 정보 결합 필요**
- (개선 방향) 앙상블 모델에 다른 유형의 모델 중 신경망, SVM을 추가 ▶ **모델 다양성 확보**
- (실무 적용) 불만족 고객 예측 결과를 **CRM 시스템과 연계**
 - **선제적 대응 프로세스 구축 및 고객 유지 전략 연결 가능**